

Индекс

Определение

- Объекты базы данных, предназначенные для ускорения поиска и выборки строк из таблицы, минимизируя количество данных, которые нужно просматривать.
- Так же индексы служат для поддержания некоторых ограничений целостности

Индекс

Как работает?

- Устанавливает соответствие между ключом (например, значением проиндексированного столбца) и строками таблицы, в которых этот ключ встречается. Строки идентифицируются с помощью TID (tuple id), который состоит из номера блока файла и позиции строки внутри блока.

Индекс

Увеличение затрат на запись

- При любой операции над проиндексированными данными — будь то вставка, удаление или обновление строк таблицы, — индексы, созданные для этой таблицы, должны быть перестроены, причем в рамках той же транзакции.

Индекс

Типы

- B-tree
- Hash
- GIN
- GiST
- BRIN

Индекс

Hash

- Единственная операция, которую поддерживает хеш-индекс, — поиск по условию равенства.
- По мере увеличения количества индексируемых строк одна из корзин расщепляется на две.
- Элементы корзин упорядочены по хеш-кодам ключей, подходящие идентификаторы эффективно находятся двоичным поиском.
- До версии PostgreSQL 10 хеш-индексы не журналировались.


Индекс

Hash

- Кластеризация таблицы по хеш-индексу не предусмотрена
- Поскольку хеш-функция не сохраняет отношение порядка, к хеш-индексу неприменимы свойства, касающиеся упорядоченности.
- Хеш-индекс не может участвовать в сканировании только индекса, поскольку не сохраняет ключ индексации и требует перепроверки по таблице.
- Хеш-индекс не работает с неопределенными значениями: операция «равно» не имеет смысла для NULL.
- Поиск значений из массива нереализован.

Индекс

B-tree



Индекс

B-tree

- Они сбалансированы, то есть все листья находятся на одной глубине. Поэтому поиск любого значения занимает одинаковое время.
- Они сильно ветвисты, то есть каждый узел содержит много элементов, часто сотни. За счет этого глубина B-деревьев получается небольшой даже для очень больших таблиц.
- Данные в индексе упорядочены по возрастанию как между узлами, так и внутри каждого узла. Узлы одного уровня связаны между собой двуполосным списком.

Индекс

B-tree


- Поиск по равенству
- Поиск по неравенству
- Поиск по диапазону
- Поиск по префиксу
- Оптимизация сортировки
- Уникальность

Индекс

B-tree

- Дубликаты «схлопываются» в одну индексную запись, содержащую ключ и список табличных идентификаторов.
- Уникальные индексы могут содержать дубликаты ключей из-за многоверсионности, поскольку индекс хранит ссылки на все версии табличных строк.

Индекс B-tree



Индекс

GiST (Generalized Search Tree)

- Не конкретный тип индекса, а фреймворк, который позволяет создавать пользовательские реализации для различных видов данных.


Индекс

R-дерево

- Идея R-дерева состоит в том, что плоскость разбивается на прямоугольники, которые в сумме покрывают все индексируемые точки.
- Индексная запись хранит ограничивающий прямоугольник, а предикат можно сформулировать так: точка лежит внутри данного ограничивающего прямоугольника.

Индекс R-дерево

- Типичный запрос, ускоряемый индексом, получает все точки, входящие в заданную область.



База знаний по курсу БД

Поиск

Проводник

Лабораторные работы
Лабораторная работа 1
Лабораторная работа 2
Теория
Тестовые задания
Креды СУБД
ERD-диаграмма

pgAdmin 4

File Object Tools Edit View Window Help

Object Explorer

Materialized Views
Operators
Procedures
Sequences
Tables (19)
country_region_currency
credit_card
currency
currency_rate
customer
person_credit_card
sales_order_detail

Задание 11

Вывести на экран названия категорий, количество подкатегорий и количество товаров в них.

Задание 12

Вывести на экран номер кредитного рейтинга и количество товаров, поставляемых компаниями, имеющими этот кредитный рейтинг.



Оглавление

Задания
Задание 1
Задание 2
Задание 3
Задание 4
Задание 5
Задание 6
Задание 7
Задание 8
Задание 9
Задание 10
Задание 11
Задание 12
Задание 13
Задание 14
Задание 15
Задание 16


Query Query History

```
1 SELECT pc.name,  
2     COUNT(ps.product_subcategory_id) as cnt,  
3     COUNT(*)  
4 FROM production.product_category AS pc  
5 LEFT JOIN production.product_subcategory AS ps  
6 USING (product_category_id)  
7 LEFT JOIN production.product AS p  
8 USING (product_subcategory_id)
```




Индекс k-NN



Индекс R-дерево



Индекс k-NN



ROV
 SQC
 ROV
 RTW
 SQC
 SVD
 SVD

Индекс

RD-дерево для полнотекстового поиска

- выбрать из набора документов те, которые соответствуют поисковому запросу.
- Для целей поиска документ приводится к специальному типу `tsvector`, который содержит лексемы и их позиции в документе.

Индекс

Полнотекстовый поиск

- Чтобы полнотекстовый поиск работал быстро, его нужно поддерживать индексом. Поскольку индексируются не сами документы, а значения типа `tsvector`, есть два варианта: построить индекс по выражению, с приведением типа, или создать отдельный столбец типа `tsvector` и индексировать его.

Индекс

RD-дерево

- R-дерево как таковое не годится для индексации документов, поскольку к ним неприменимо понятие ограничивающего прямоугольника. Используется модификация этого подхода — RD-дерево (Russian Doll, матрешка).
- Вместо ограничивающего прямоугольника это дерево использует ограничивающее множество, то есть множество, содержащее все элементы дочерних множеств.


Индекс

Сигнатурное дерево

- В ней используется фильтр Блума. Каждую лексему можно представить своей сигнатурой: битовой строкой определенной длины, в которой все биты равны нулю (сброшены), кроме одного, который равен единице (установлен). Номер установленного бита определяется значением хеш-функции от лексемы.

Индекс

Сигнатурное дерево



Индекс

GIN (Generalized Inverted Index)

- Тип индексной структуры, который предназначен для работы с коллекциями данных и для быстрого поиска по составным структурам. Он особенно эффективен для ситуаций, когда одно поле содержит множество значений.

Индекс

Аналогия

- предметный указатель в конце книги. В указателе собраны все важные термины, и для каждого приведен список страниц, на которых этот термин упоминается. Чтобы указателем было удобно пользоваться, он составляется по алфавиту, иначе в нем невозможно было бы быстро ориентироваться. Так и GIN полагается на то, что элементы составных значений можно упорядочить, и в качестве основной структуры использует b-tree

Индекс GIN

