

# **Индекс**

## **Определение**

- Объекты базы данных, предназначенные для ускорения поиска и выборки строк из таблицы, минимизируя количество данных, которые нужно просматривать.
- Так же индексы служат для поддержания некоторых ограничений целостности



# Индекс

## Как работает?

- Устанавливает соответствие между ключом (например, значением проиндексированного столбца) и строками таблицы, в которых этот ключ встречается. Строки идентифицируются с помощью TID (tuple id), который состоит из номера блока файла и позиции строки внутри блока.



# Индекс

## Увеличение затрат на запись

- При любой операции над проиндексированными данными — будь то вставка, удаление или обновление строк таблицы, — индексы, созданные для этой таблицы, должны быть перестроены, причем в рамках той же транзакции.



# Индекс

## Типы

- B-tree
- Hash
- GIN
- GiST
- BRIN



# Индекс

## Hash

- Единственная операция, которую поддерживает хеш-индекс, — поиск по условию равенства.
- По мере увеличения количества индексируемых строк одна из корзин расщепляется на две.
- Элементы корзин упорядочены по хеш-кодам ключей, подходящие идентификаторы эффективно находятся двоичным поиском.
- До версии PostgreSQL 10 хеш-индексы не журналировались.



# Индекс


## Hash

- Кластеризация таблицы по хеш-индексу не предусмотрена
- Поскольку хеш-функция не сохраняет отношение порядка, к хеш-индексу неприменимы свойства, касающиеся упорядоченности.
- Хеш-индекс не может участвовать в сканировании только индекса, поскольку не сохраняет ключ индексации и требует перепроверки по таблице.
- Хеш-индекс не работает с неопределенными значениями: операция «равно» не имеет смысла для NULL.
- Поиск значений из массива нереализован.



# Индекс

## B-tree





# Индекс

## B-tree

- Они сбалансированы, то есть все листья находятся на одной глубине. Поэтому поиск любого значения занимает одинаковое время.
- Они сильно ветвисты, то есть каждый узел содержит много элементов, часто сотни. За счет этого глубина B-деревьев получается небольшой даже для очень больших таблиц.
- Данные в индексе упорядочены по возрастанию как между узлами, так и внутри каждого узла. Узлы одного уровня связаны между собой двуправленным списком.



# Индекс

## B-tree

- Поиск по равенству
- Поиск по неравенству
- Поиск по диапазону
- Поиск по префиксу
- Оптимизация сортировки
- Уникальность




# Индекс

## B-tree

- Дубликаты «схлопываются» в одну индексную запись, содержащую ключ и список табличных идентификаторов.
- Уникальные индексы могут содержать дубликаты ключей из-за многоверсионности, поскольку индекс хранит ссылки на все версии табличных строк.



# Индекс B-tree





# **Индекс**

## **GiST (Generalized Search Tree)**

- Не конкретный тип индекса, а фреймворк, который позволяет создавать пользовательские реализации для различных видов данных.



# Индекс


## R-дерево

- Идея R-дерева состоит в том, что плоскость разбивается на прямоугольники, которые в сумме покрывают все индексируемые точки.
- Индексная запись хранит ограничивающий прямоугольник, а предикат можно сформулировать так: точка лежит внутри данного ограничивающего прямоугольника.



# Индекс R-дерево

- Типичный запрос, ускоряемый индексом, получает все точки, входящие в заданную область.



## База знаний по курсу БД

Поиск

Проводник

Лабораторные раб  
Лабораторная р  
Лабораторная р  
Теория  
Тестовые задан  
Креды СУБД  
ERD-диаграмма

pgAdmin 4  
File Object Tools Edit View Window Help  
Object Explorer  
Materialized Views  
Operators  
Procedures  
Sequences  
Tables (19)  
country\_region\_currency  
credit\_card  
currency  
currency\_rate  
customer  
person\_credit\_card  
sales\_order\_detail

Dependencies Dependents Processes

aw/student@aw.sqlwars.ru

No limit

Query Query History

Scratch Pad

1 SELECT pc.name,

2 COUNT(ps.product\_subcategory\_id) as cnt,

3 COUNT

4 FROM production.product\_category AS pc

5 LEFT JOIN production.product\_subcategory AS ps

6 USING (product\_category\_id)

7 LEFT JOIN production.product AS p

8 USING (product\_subcategory\_id)

Оглавление

Задания

Задание 1

Задание 2

Задание 3

Задание 4

Задание 5

Задание 6

Задание 7

Задание 8

Задание 9

Задание 10

Задание 11

Задание 12

Задание 13



Задание 14

Задание 15

Задание 16




# Индекс k-NN







# Индекс R-дерево





# Индекс k-NN



ROV  
 SQC  
 ROV  
 RTW  
 SQC  
 SVD  
 SQC  
 SVD



# Индекс

## RD-дерево для полнотекстового поиска

- выбрать из набора документов те, которые соответствуют поисковому запросу.
- Для целей поиска документ приводится к специальному типу `tsvector`, который содержит лексемы и их позиции в документе.



# Индекс

## Полнотекстовый поиск

- Чтобы полнотекстовый поиск работал быстро, его нужно поддерживать индексом. Поскольку индексируются не сами документы, а значения типа `tsvector`, есть два варианта: построить индекс по выражению, с приведением типа, или создать отдельный столбец типа `tsvector` и индексировать его.



# Индекс

## RD-дерево

- R-дерево как таковое не годится для индексации документов, поскольку к ним неприменимо понятие ограничивающего прямоугольника. Используется модификация этого подхода — RD-дерево (Russian Doll, матрешка).
- Вместо ограничивающего прямоугольника это дерево использует ограничивающее множество, то есть множество, содержащее все элементы дочерних множеств.



# Индекс


## Сигнатурное дерево

- В ней используется фильтр Блума. Каждую лексему можно представить своей сигнатурой: битовой строкой определенной длины, в которой все биты равны нулю (сброшены), кроме одного, который равен единице (установлен). Номер установленного бита определяется значением хеш-функции от лексемы.



# Индекс

## Сигнатурное дерево





# Индекс

## GIN (Generalized Inverted Index)

- Тип индексной структуры, который предназначен для работы с коллекциями данных и для быстрого поиска по составным структурам. Он особенно эффективен для ситуаций, когда одно поле содержит множество значений.



# **Индекс**

## **Аналогия**

- предметный указатель в конце книги. В указателе собраны все важные термины, и для каждого приведен список страниц, на которых этот термин упоминается. Чтобы указателем было удобно пользоваться, он составляется по алфавиту, иначе в нем невозможно было бы быстро ориентироваться. Так и GIN полагается на то, что элементы составных значений можно упорядочить, и в качестве основной структуры использует b-tree



# Индекс GIN

