


Хеш-таблица

- Данные хранятся в файле, который можно только дополнять (append-only log).
- В оперативной памяти хранится хеш-таблица (словарь).
- Ключ → Смещение (offset) в файле данных.




Хеш-таблица

- Запись: Добавляем пару "ключ-значение" в конец файла и обновляем хеш-таблицу.
- Чтение: По ключу находим смещение в хеш-таблице, переходим по нему в файл и читаем значение.

Хеш-таблица Сегменты


- Разбить журнал на сегменты фиксированного размера.
- При заполнении сегмента — закрыть его и начать новый.
- Запустить фоновый процесс уплотнения (compaction) и слияния (merging) сегментов.



Хеш-таблица

Слияние

- Объединение нескольких небольших сегментов в один новый.
- Позволяет уменьшить общее количество сегментов.




Хеш-таблица

Алгоритм чтения:

- Поиск начинается в хеш-таблице самого свежего сегмента.
- Если ключ не найден — проверяется следующий по старшинству сегмент.
- И так далее, пока ключ не будет найден или не будут проверены все сегменты.

Хеш-таблица




↓UG
↓RIG
↓G1
10-1
10

Хеш-таблица

Ограничение


- Ключи должны помещаться в ОЗУ. Хеш-таблица на диске медленная из-за случайных чтений, дорогого расширения и сложности разрешения коллизий.
- Неэффективные запросы по диапазону. Невозможно быстро найти все ключи от 00000 до 99999. Необходимо обращаться к хеш-таблице для каждого ключа в диапазоне отдельно.



SS-table


Особенности

- Данные отсортированы по ключу
- Каждый ключ встречается только один раз (обеспечивается уплотнением)
- Порядок записи значений не важен - приоритет у более новых значений




Слияние

- Алгоритм, аналогичный сортировке слиянием
- Работает даже когда данные не помещаются в оперативной памяти
- При конфликте ключей берется значение из самого нового сегмента




Разряженный индекс

- Не нужно хранить все ключи - только некоторые ориентиры
- Пример: известны смещения для "handbag" и "handsome" → "handiwork"
- Можно быстро просканировать небольшой диапазон
-




MemTable

- Сбалансированное дерево в оперативной памяти (красно-черное, AVL)
- Данные сохраняются отсортированными по ключу
- Быстрая вставка в любом порядке




Надежность

- Все операции немедленно записываются в журнал
- Журнал неупорядочен - используется только для восстановления
- После записи MemTable в SS-таблицу журнал удаляется



Алгоритм работы

- Запись: Добавляется в MemTable и параллельно пишется в журнал для надежности
- Чтение: Поиск в MemTable → последнем сегменте → предыдущем и т.д.
- Фоновые процессы: При превышении лимита MemTable записывается в SS-таблицу, Регулярное слияние и уплотнение сегментов




LSM-дерево

Фильтр Блума


- Эффективная проверка отсутствия ключа
- Избегание ненужных чтений с диска
- "Возможно есть" / "Точно нет"

Index



Алгоритм работы

- Запись: Добавляется в MemTable и параллельно пишется в журнал для надежности
- Чтение: Поиск в MemTable → последнем сегменте → предыдущем и т.д.
- Фоновые процессы: При превышении лимита MemTable записывается в SS-таблицу, Регулярное слияние и уплотнение сегментов





Уплотнение

- Size-tiered: Объединение маленьких SS-таблиц в большие
- Leveled: Разбиение по уровням с постепенным перемещением
- Разные компромиссы между скоростью и использованием диска

Tree

SS-TABLE
SUMMARY





В-Деревья

Опасность операций с множеством страниц

- Разбиение страницы при переполнении
- Запись двух новых страниц
- Обновление родительской страницы

Node
Merge Tree

БУМ
STABLE
СЛУЖИМ



Write-Ahead Log

- Файл только для добавления (append-only)
- Быстрая последовательная запись
- Используется для восстановления после сбоев

Index
Merge Tree

PILOT BURN
VAL

SS-TABLE
SAMPLING





LOG
P-1
Q

Защелки (latches)

- Облегченные версии блокировок
- Защита структур данных при одновременном доступе
- Высокая производительность

Nodes
Merge Tree

БЛОК
SSTABLE
SUMMARY




Улучшение: Копирование при записи

- Принцип: Измененные страницы записываются в новое место
- Отказ от WAL
- Упрощение управления конкурентным доступом
- Поддержка изоляции снимков состояния

Range Index
fractal Merge Tree


ФИЛЕТ БУМ
WAL

STABLE
SUMMARY



- LSM-деревья: Обычно быстрее при записи
- B-деревья: Обычно быстрее при чтении

Range Index
Procedural Merge Tree



Модель доступа

Дискреционная модель доступа

- Модель управления доступом, при которой владельцы объектов (например, таблиц, схем, представлений) в базе данных самостоятельно определяют, кто и какие действия может выполнять с этими объектами.

